

Crie seu pipeline de dados sem pagar por isso!

Erika Nagamine 23.03.21 12h00









Este trabalho está licenciado sob uma Licença Creative Commons Atribuição-Compartilhalgual 4.0 Internacional.

Para ver uma cópia desta licença, visite http://creativecommons.org/licenses/by-sa/4.0/.





Índice

1.	Co	nsiderações iniciais e pre requisitos	4
	Recu	rsos usados:	4
•	Tópio	cos não cobertos:	4
2.	Pro	ovisionar os recursos	5
	2.1.	Object Storage	5
	2.2.	Criando funções	7
	2.3.	Criando uma evento	13
	2.4.	Banco de dados Autonomous	15
3.	Co	nfigurando seu ambiente	17
4.	Te	stando seu pipeline de dados	22
5. Referências			3C

1. Considerações iniciais e pré requisitos

A técnica demonstrada aqui no presente documento é apenas uma das que pode ser utilizada para criar um pipeline de dados. É possível utilizar outras técnicas dependendo do seu caso de uso. Para deixar o passo a passo de uma maneira única, padronizamos as telas em inglês.

Recursos usados:

OCI (all free tier)

- Armazenamento Oracle Object storage
- Functions (30 days free)
- Events (30 days free)
- Pacotes Oracle Instant Client + Tools e sqlplus
- Banco de dados autonomous (adw)
- Compute VM 2.1 Shape

Local

Navegador

Tópicos não cobertos:

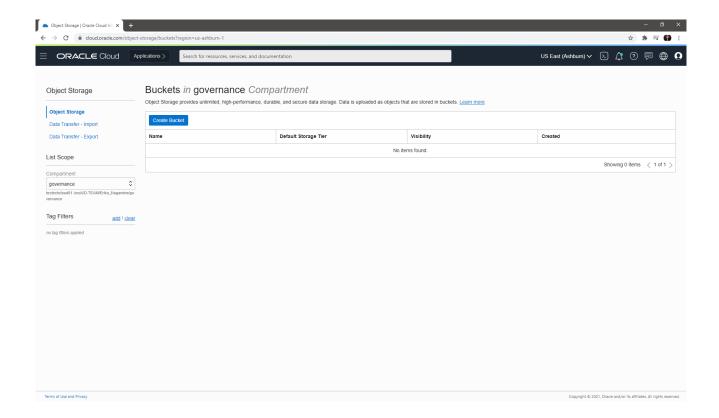
Configuração da máquina adicional para criação de funções

- É possível criar funções através de um computador Always Free, mas não cobriremos essa possibilidade no documento
- Não focaremos na visualização do dados que dentro do serviço de OAC (Oracle analytics Cloud),
 Oracle Machine Learning Notebooks presente no autonomous ou um relatório via APEX
- A infraestrutura completa também pode ser provisionada via infraestrutura como um código
- Temos por pressuposto que você possui acesso a cloud não cobriremos o tópico de fundação e boas práticas na cloud, como criação de compartments, etc.

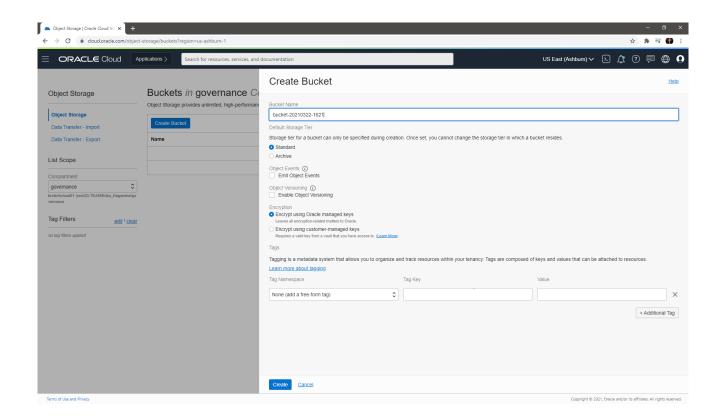
2. Provisionar os recursos

2.1.Object Storage

O object storage é um disco elástico para armazenamento dos mais diversos tipos de arquivos e cargas de trabalho: pode armazenar desde um dado não estruturado até um backup. Para criar um object storage, vá em menu -> Object storage -> object storage:



Iremos criar dois buckets onde um servirá para os dados processados e o outro para dados inseridos (onde vamos receber as informações. Na tela, clique na opção de "create bucket".



Crie dois buckets com as seguintes informações:

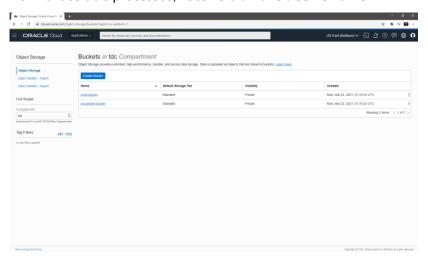
(bucket de entrada de dados)

- Bucket-name: input-bucket
- Object Events: Marque a opção para emitir eventos

(bucket de saida de dados)

- Bucket-name: processed-bucket
- Object Events: Marque a opção para emitir eventos

Ao final dos dois processos, você verá uma tela semelhante:

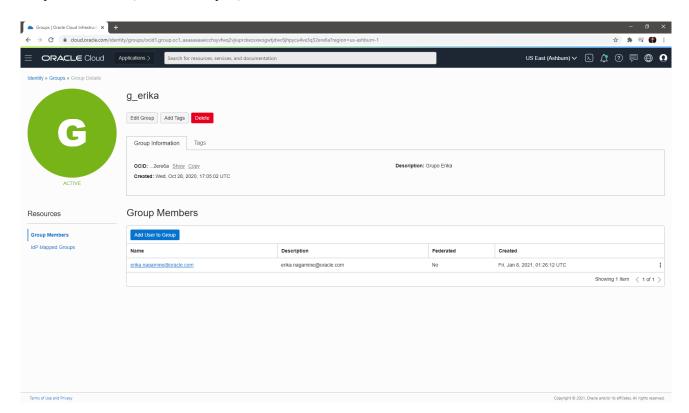


2.2. Criando funções

Alguns pré requisitos deverão ser realizados para esta fase:

Criação de grupos

Em menu -> identity -> groups crie um grupo para atribuir as politicas necessárias a criação de funções. Um exemplo desta criação pode ser este:

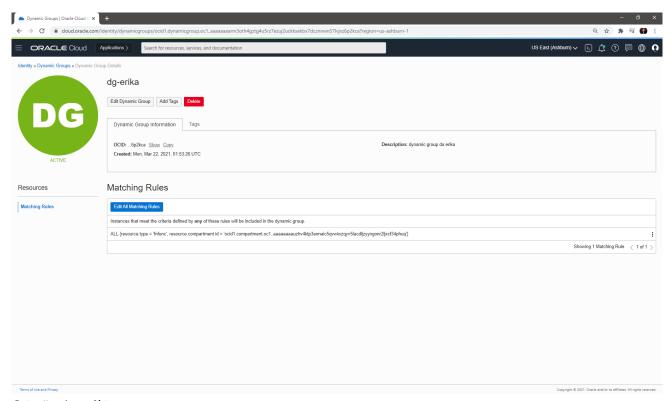


Atribua todos os usuários que precisam ter acesso a este grupo.

• Crie um grupo dinâmico

Para atribuição de permissões sobre seu compartment especifico, utilize o recurso de grupo dinâmico. Para cria-lo vá em menu -> identity -> Dynamic Group

```
ALL {resource.type = 'fnfunc', resource.compartment.id =
   'id_do_compartment'}
```



 Criação de políticas
 Em menu -> identity - Policies crie as politicas necessárias para esta fase. As politicas necessárias são descritas abaixo:

Allow group g_erika to use cloud-shell in tenancy

Allow group g_erika to manage repos in tenancy

Allow group g_erika to read objectstorage-namespaces in tenancy

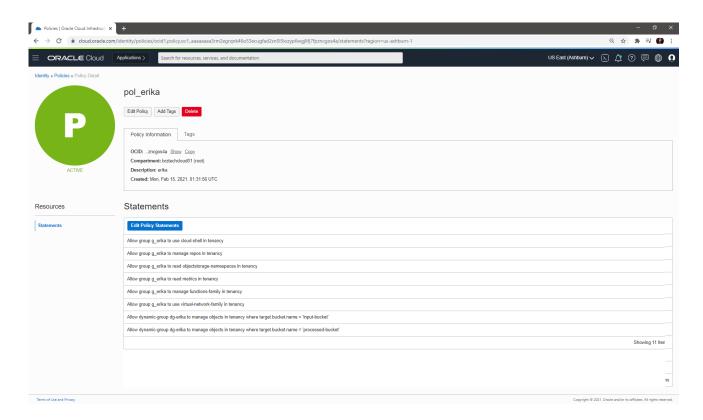
Allow group g_erika to read metrics in tenancy

Allow group g_erika to manage functions-family in tenancy

Allow group g_erika to use virtual-network-family in tenancy

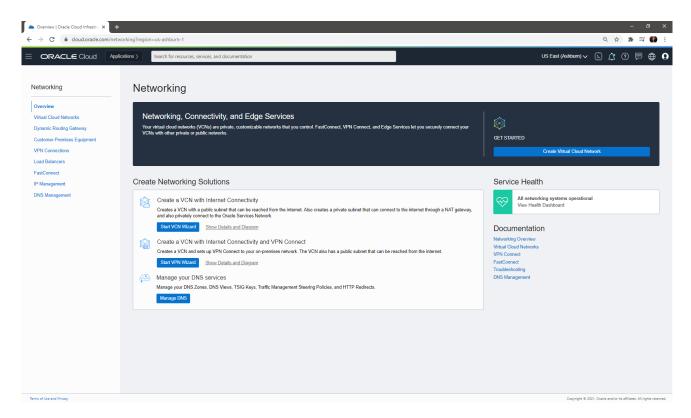
Allow dynamic-group dg-erika to manage objects in compartment <seu compartment> where target.bucket.name=input-bucket

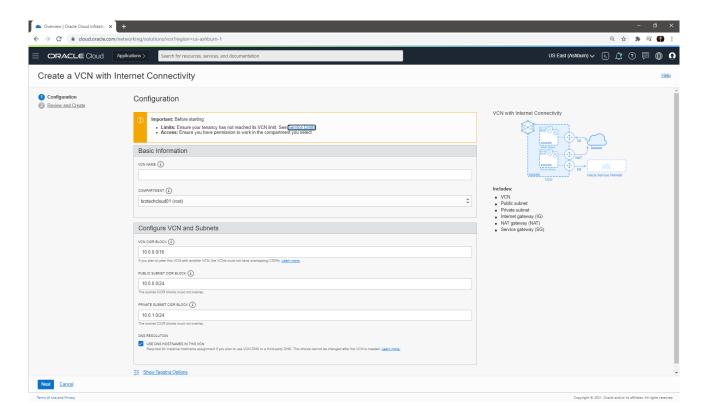
Allow dynamic-group dg-erika to manage objects in compartment <seu compartment> where target.bucket.name=processed-bucket



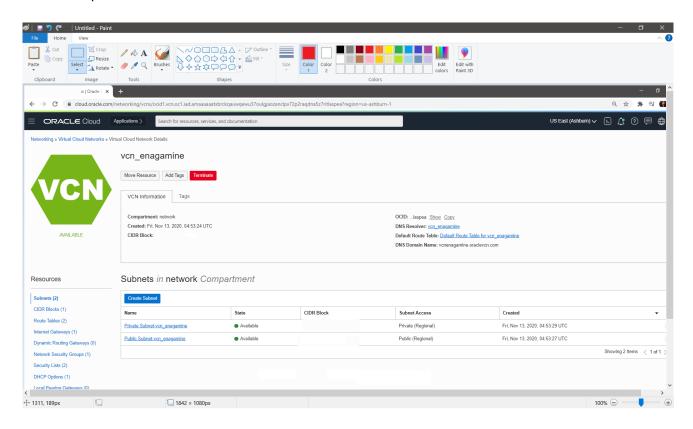
Criação de VCN

Neste documento criaremos uma rede padrão via "wizard" mas como padrão e boa pratica, pense sempre na boa fundação do seus recursos em cloud. Para criar a rede padrão, vá em menu -> networking -> start VCN Wizard e siga o passo a passo:

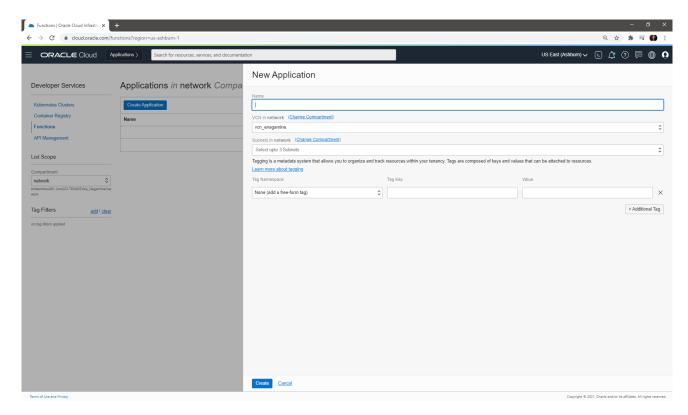




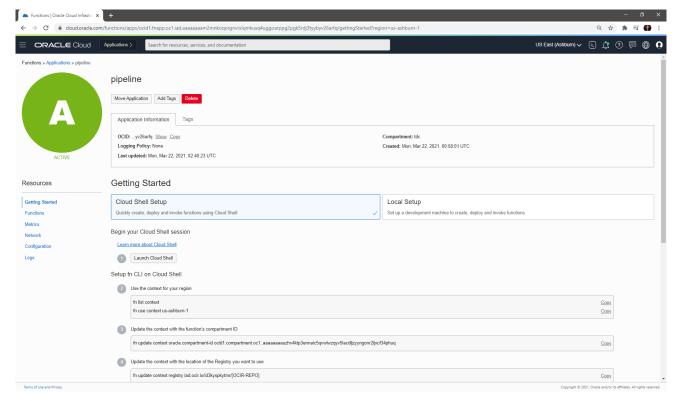
Ao final do processo você terá duas subnets:



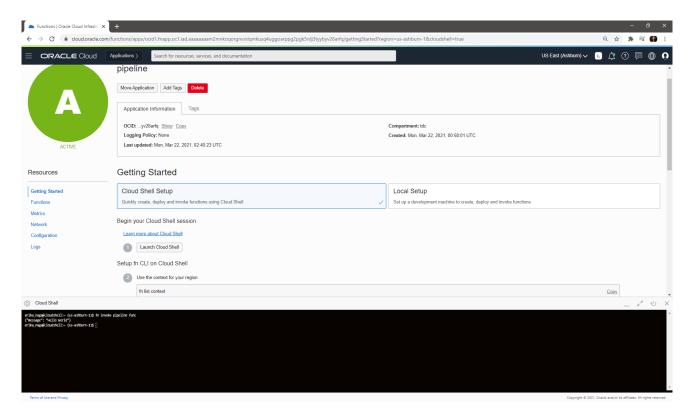
Agora estamos pronto para o processo de criação de funções. Para isso, vá em menu -> developer services -> functions e clique em create application:



Você precisará informar sua VCN criada. Sugerimos (para efeito de workshop, não de dia a dia, colocar na subnet publica).



Após criar sua aplicação para a função, agora vamos configurá-la. Para isso faremos o setup via cloud shell. Siga o passo a passo da página e não se esqueça de gerar e anotar o token:



Agora que a configuração básica da sua função está realizada, no cloud shell baixe os scripts abaixo e coloque os no diretório func:

```
wget https://raw.githubusercontent.com/oracle/oracle-functions-
samples/master/samples/oci-load-file-into-adw-python/func.py

wget https://raw.githubusercontent.com/oracle/oracle-functions-
samples/master/samples/oci-load-file-into-adw-
python/requirements.txt

wget https://raw.githubusercontent.com/oracle/oracle-functions-
samples/master/samples/oci-load-file-into-adw-python/func.yaml
```

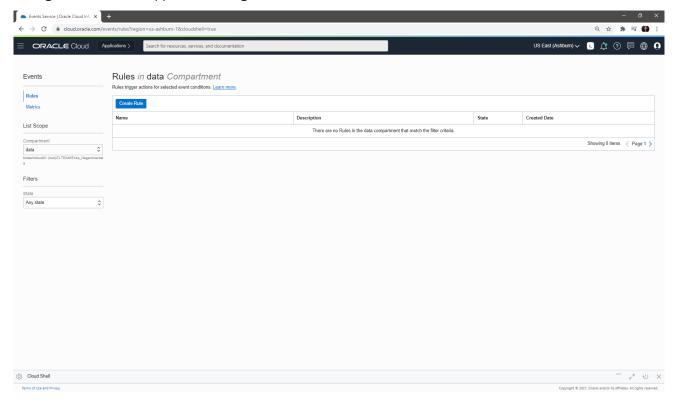
Faça o deploy da sua função com novas parametrizações:

```
fn -v deploy --app pipeline func
```

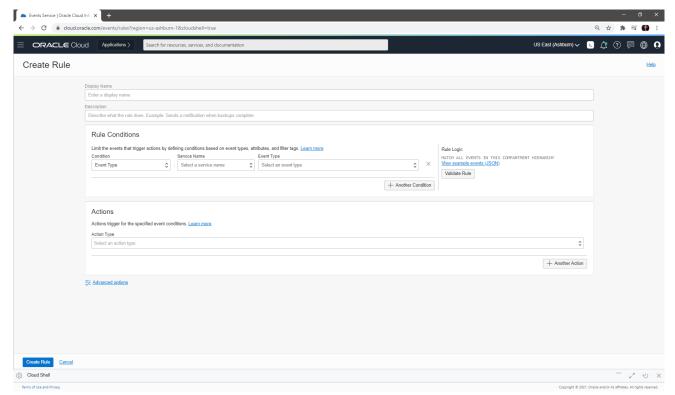
Retornaremos a este passo posteriormente para configurar os parâmetros que sua função irá receber.

2.3. Criando uma evento

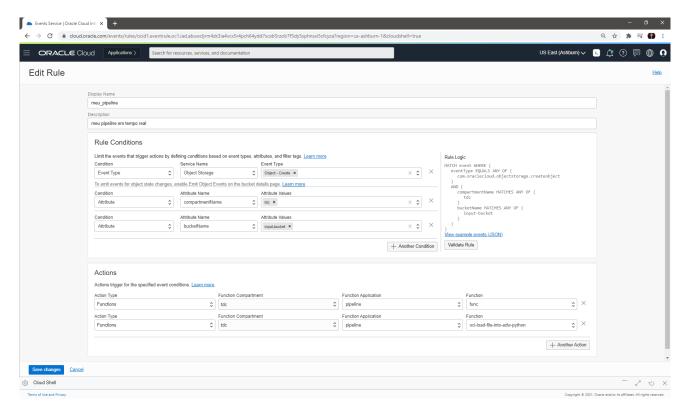
Navegue até menu -> application integration -> event service



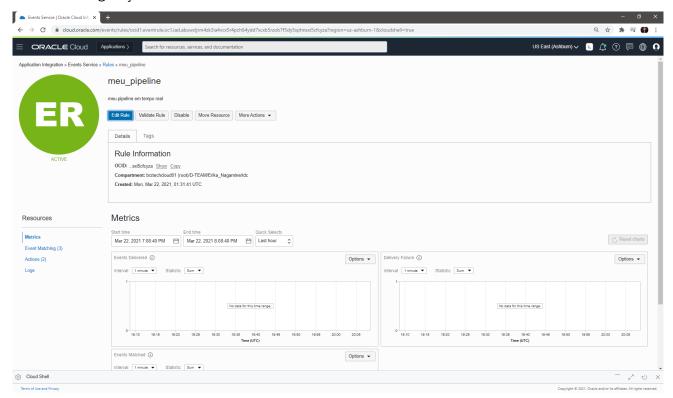
Clique em criar uma nova regra:



Utilize as parametrizações abaixo:



Salve as configurações:

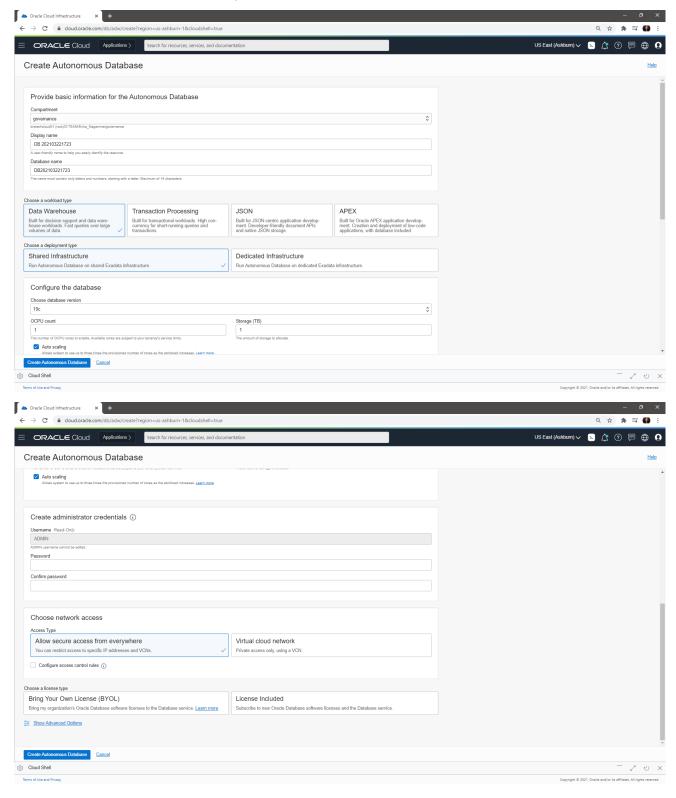


Nesse momento seu data lake está pronto para receber os dados. Faremos a configuração do nosso data warehouse

2.4. Banco de dados Autonomous

Nosso Data warehouse será construído em cima do autonomous database. Navegue no menu direito até autonomous database e clique em criar autonomous data warehouse.

Em autonomous data warehouse clique em "create autonomous database:



Preencha com as seguintes informações (note que é possível provisionar o autonomous como Always free:

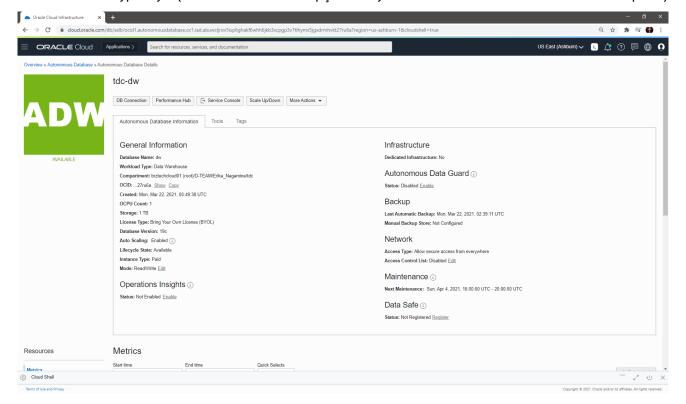
• Compartment: se você criou um compartment, selecione o responsável:

Display name: tdc-dwDatabase name: dwDatabase version: 19c

Workload type: data warehouse

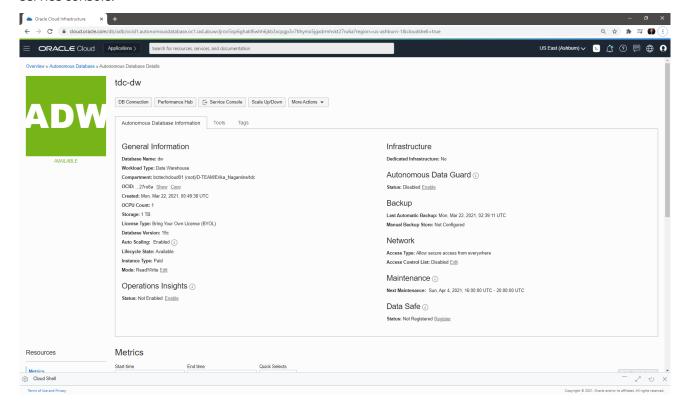
User password: coloque uma de sua escolha

License type: Byol (se você selecionou a opção Always free do autonomous desconsidere essa parte)

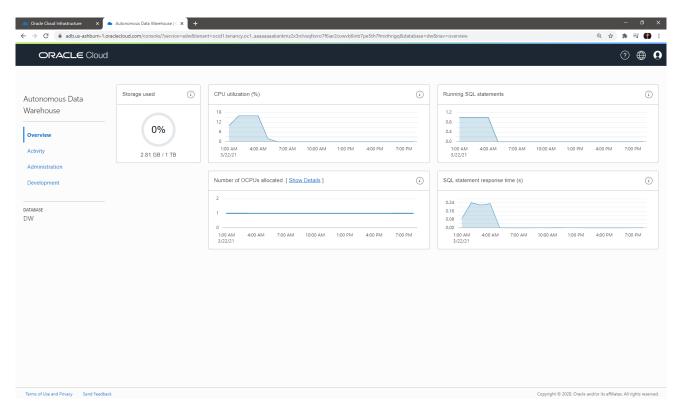


3. Configurando seu ambiente

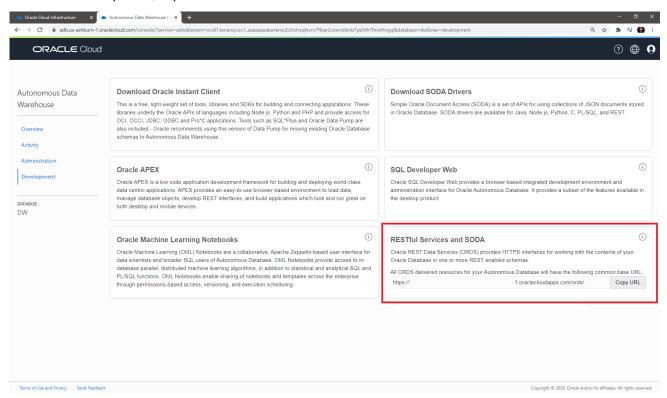
Agora que o stack está provisionado, vamos integrar os recursos. O primeiro passo é validar sua conexão via API para o Autonomous database e criar uma colection. Vamos fazer isso tudo através de linha de comando no cloud shell. Vamos pegar a informação necessária para este step, vá no autonomous criado e clique em service console:



Dentro da service console, navegue em development:



Dentro de development, copie a URL do RESTful services and SODA:



Agora substitua as variaveis abaixo e execute no seu

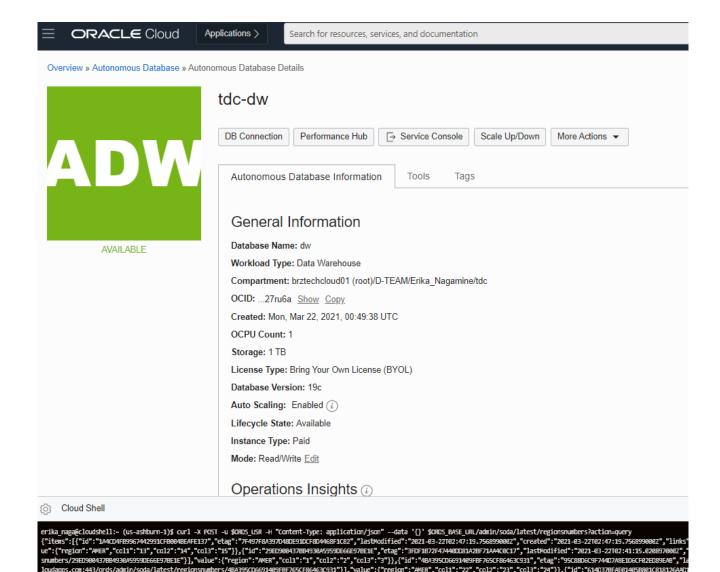
export ORDS_BASE_URL=< URL do SEU ADW – Restful and SODA> export ORDS_USR='<usuario>:<senha>'

curl -X PUT -u \$ORDS_USR -H "Content-Type: application/json" \$ORDS_BASE_URL/admin/soda/latest/regionsnumbers

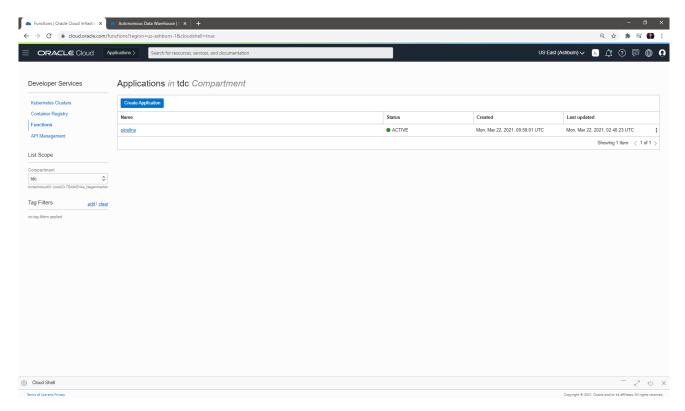
curl -u \$ORDS_USR -H "Content-Type: application/json" \$ORDS_BASE_URL/admin/soda/latest/

curl -X POST -u \$ORDS_USR -H "Content-Type: application/json" --data '{}' \$ORDS_BASE_URL/admin/soda/latest/regionsnumbers?action=query

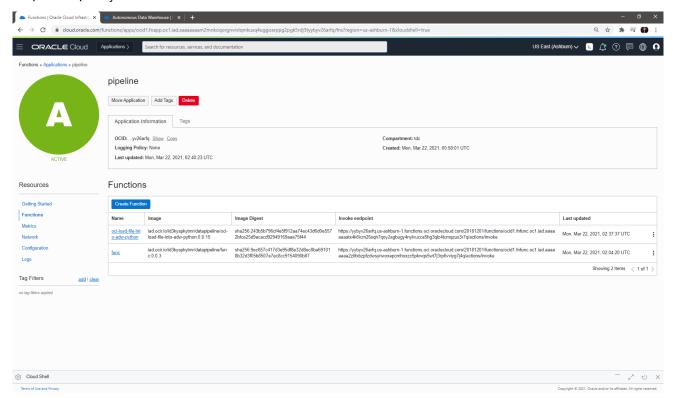
curl -X POST -u \$ORDS_USR -H "Content-Type: application/json" \$ORDS_BASE_URL/admin/soda/latest/regionsnumbers?action=truncate



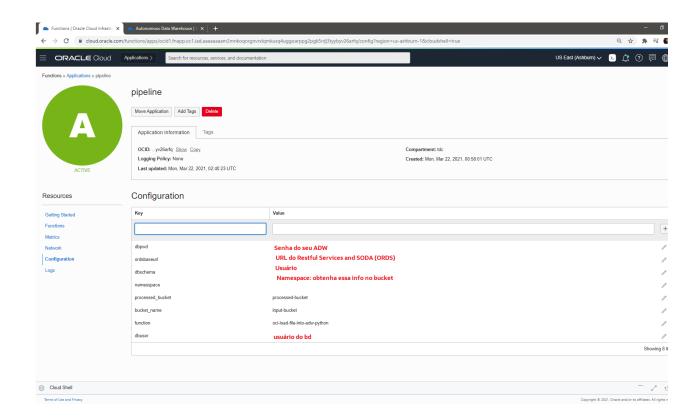
Mediante a esse funcionamento, o próximo passo é configurar a parametrização básica da sua função. Para isso vá em developer services -> functions:



Clique na aplicação criada:



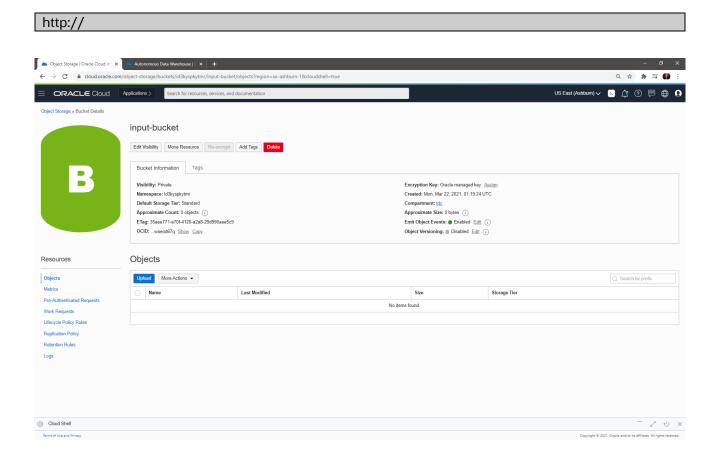
Vá em configuração e sete as seguintes parametrizações:

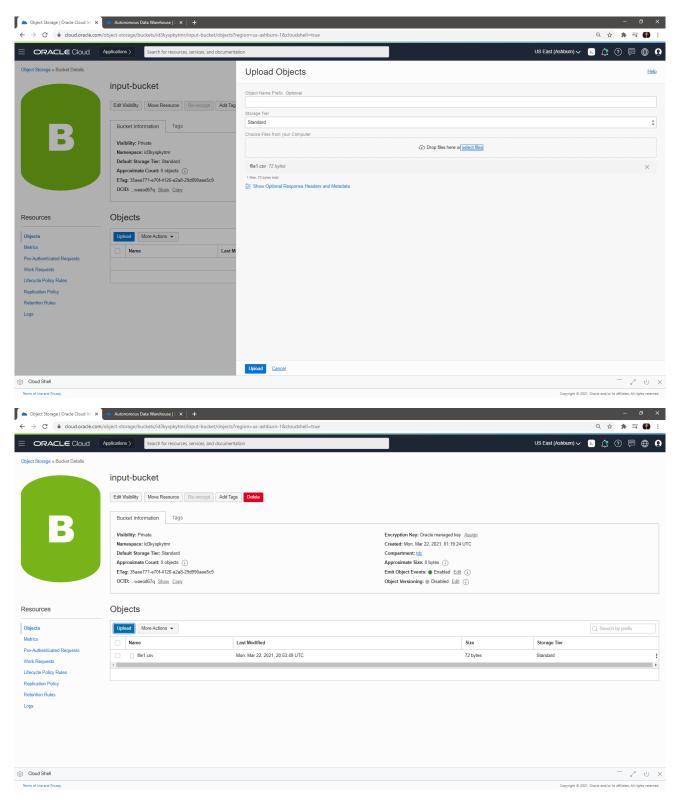


Pronto! Agora você está pronto para testar seu pipeline! 😊

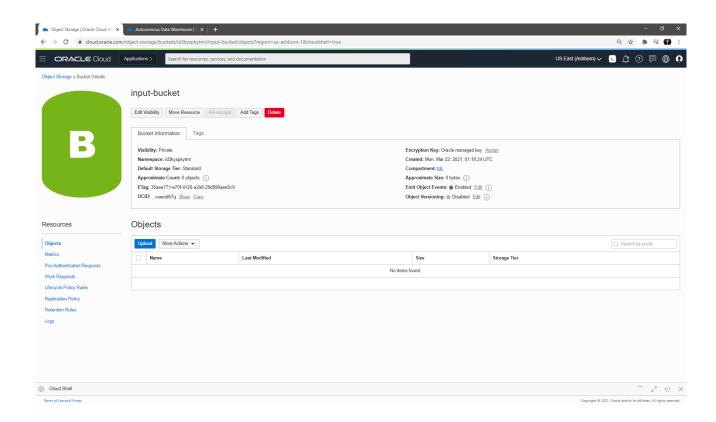
4. Testando seu pipeline de dados

Agora que o stack está todo configurado, é só colocar um arquivo no bucket input-bucket. Os arquivos de exemplo podem ser baixados do github:

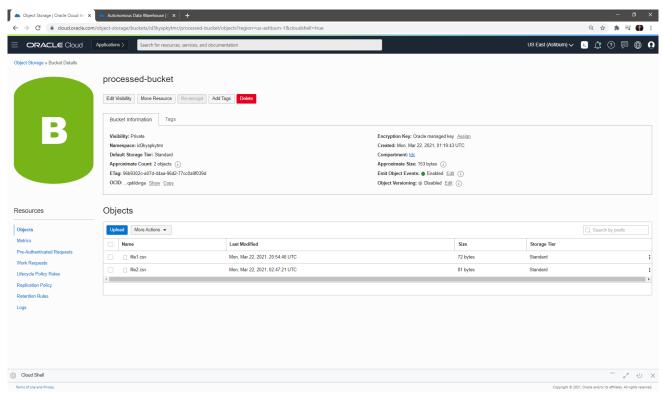




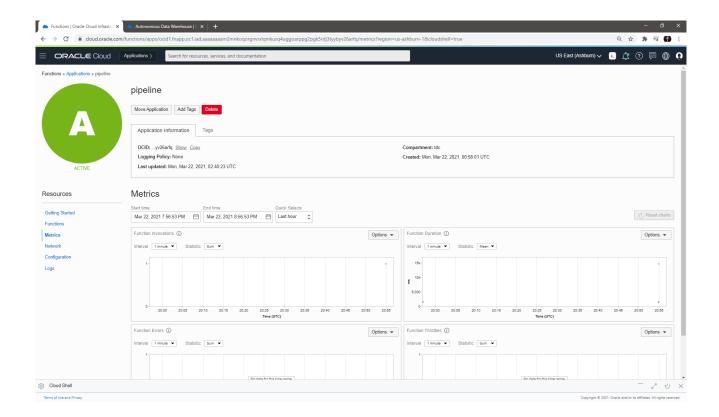
Aguarde um momento até o processo ser concluído. Quando ele for, veja que o arquivo não estará mais presente no bucket input-bucket – o tempo do processo depende do tamanho do arquivo (se for os de exemplo, note que será menos de 1 min):



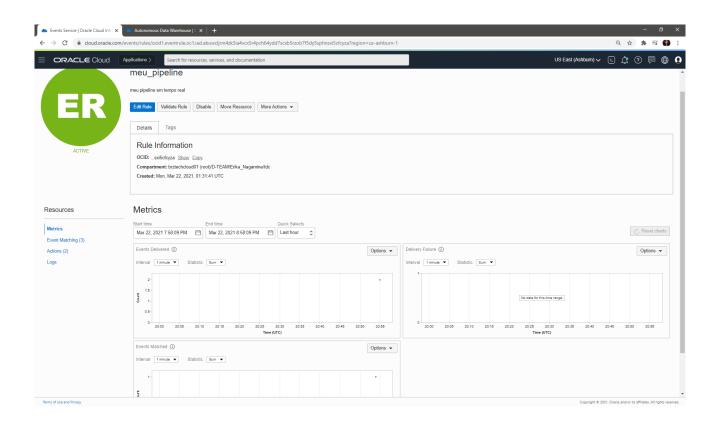
Ao final do processo você terá o arquivo dentro do bucket processed bucket:



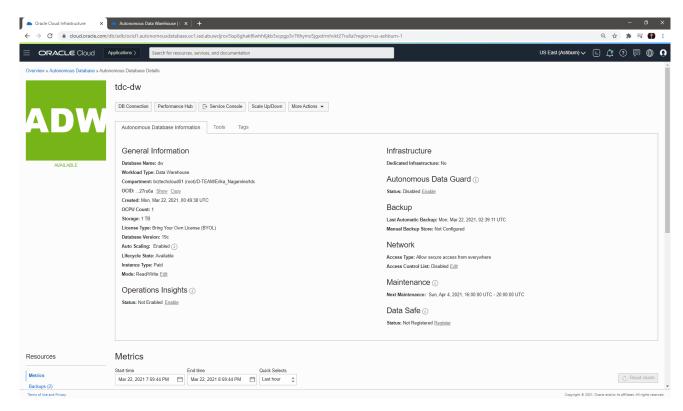
Note que seu processo estará nas métricas da função:



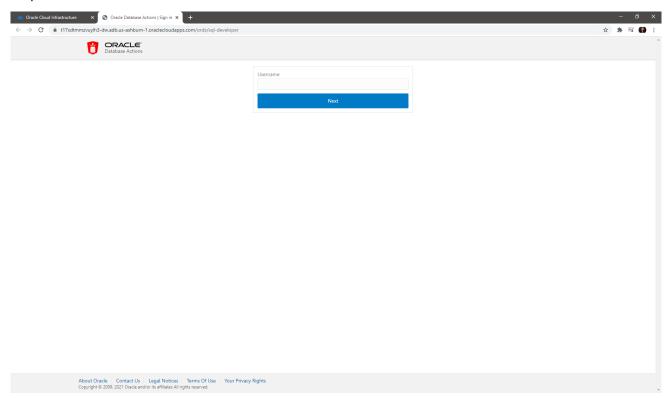
E nas métricas do evento:



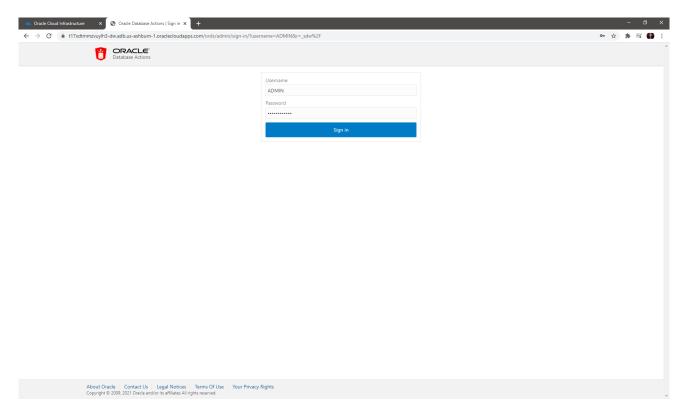
Você também pode fazer a validação dentro do seu dw, para isso vá no ADW:



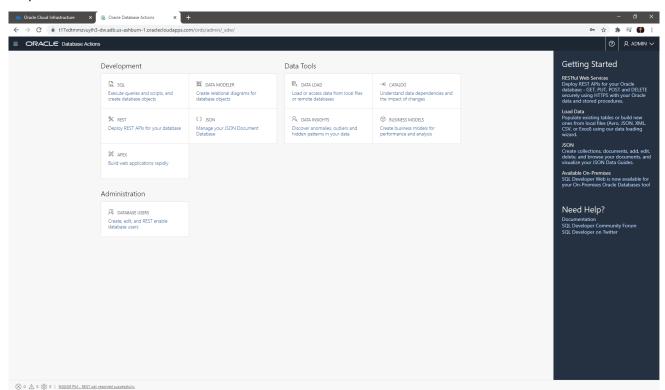
Clique em tools -> database actions:



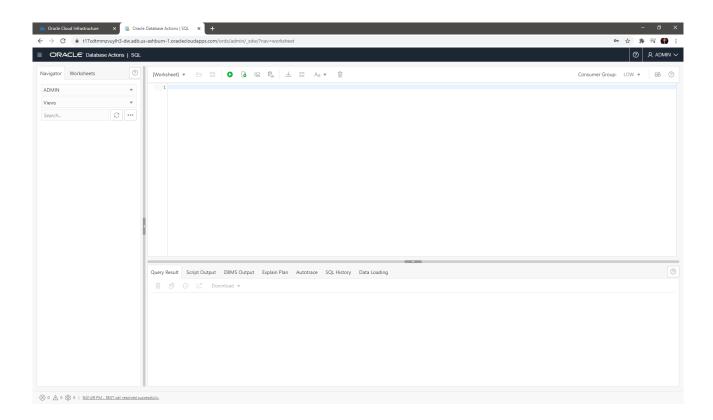
Insira seu usuário e senha:



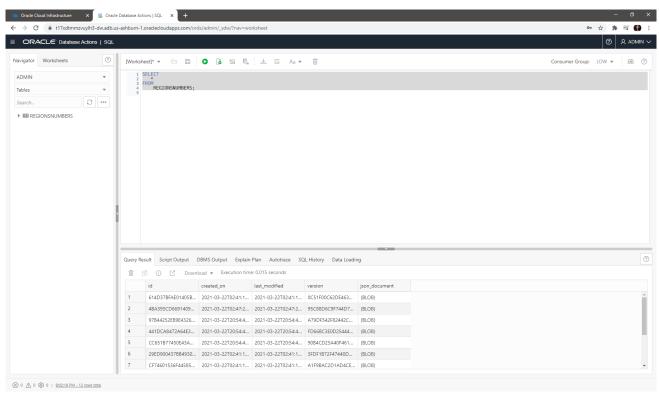
Clique em SQL:



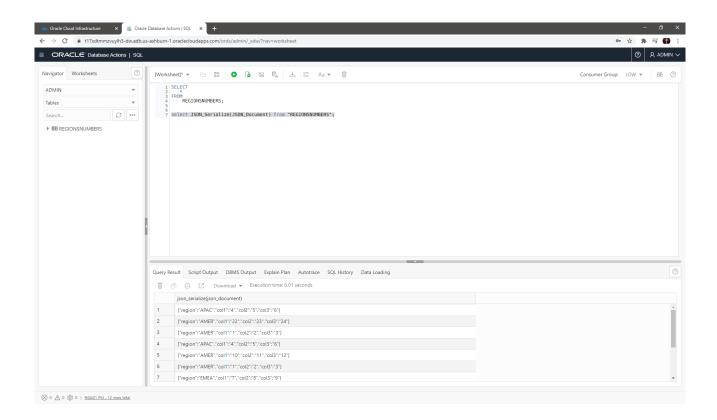
Na tela de SQL, faça a query no objeto criado:



Ao realizar q query note que ela aparece como objeto json:



Veja que é possível melhorar a visualização utilizando os recursos json:



5. Referências

Algumas documentações importantes:

- Functions:
 - https://www.oracle.com/webfolder/technetwork/tutorials/infographics/oci_functions_cloudshell_quickview/functions_quickview_top/functions_quickview/index.html#
- OCI Examples: https://github.com/oracle/oracle-functions-samples/tree/master/samples/oci-load-file-into-adw-python
- Archicture Reference: https://docs.oracle.com/en/solutions/serverless-dataload-adw/index.html#GUID-36A94B9D-0B06-4A4A-81B0-A292392181BD